

Previsão de Aprovação de Crédito com Machine Learning

Integrantes

- Matheus Felipe Campioto Catenacci — RA: 22014137-2
 - André Felipe Ferrari de Azevedo — RA: 22120196-2
-

Resumo do Projeto

Contextualização

A concessão de crédito é uma das atividades mais críticas do setor financeiro. Conceder crédito a um cliente de alto risco pode gerar prejuízos significativos, enquanto negar crédito a um bom pagador representa perda de receita. A inteligência artificial permite automatizar e tornar esse processo mais preciso e justo.

Problema

Como prever se um cliente será um bom ou mau pagador com base em suas características financeiras e pessoais?

Hipótese

É possível construir um modelo de IA capaz de classificar o risco de crédito de um cliente com acurácia superior a 70%, utilizando características como idade, valor do crédito, duração do empréstimo e histórico financeiro.

Dataset

Nome: German Credit Data

Origem: UCI Machine Learning Repository / Kaggle

Registros: 1.000 clientes

Variável alvo: Risk (good = bom pagador / bad = mau pagador)

Distribuição: 70% bons pagadores / 30% maus pagadores

Divisão: 80% treino / 20% teste

Atributos principais:

- Age (idade)
- Sex (sexo)
- Job (trabalho)
- Housing (moradia)
- Saving accounts (poupança)

- Checking account (conta corrente)
- Credit amount (valor do crédito)
- Duration (duração em meses)
- Purpose (finalidade)

Métodos de IA Utilizados

Parte 1 — Modelo Preditivo: Random Forest

Random Forest é um método de ensemble que cria múltiplas árvores de decisão independentes e combina suas previsões por votação majoritária. É robusto contra overfitting e lida bem com dados desbalanceados.

Parâmetros: n_estimators=100, random_state=42

Parte 2 — Modelo Descritivo: K-Means Clustering

K-Means é um algoritmo de agrupamento não supervisionado que segmenta os clientes em K grupos com características similares. Utilizamos o método do cotovelo para determinar K=3 como o número ideal de clusters.

Avaliação dos Modelos

Random Forest — Métricas obtidas:

Métrica	Valor
Acurácia	84.50%
F1-Score	0.8456
Precisão	0.8473
Revocação	0.8450

Gráficos gerados:

- random_forest_resultados.png — Matriz de confusão e importância das features
- metodo_cotovelo.png — Escolha do K ideal para K-Means
- kmeans_resultados.png — Clusters visualizados com PCA e distribuição por cluster

Comparação dos Resultados

Modelo	Tipo	Acurácia	Objetivo
Random Forest	Supervisionado (Preditivo)	84.50%	Classificar bom/mau pagador
K-Means	Não Supervisionado (Descritivo)	N/A	Segmentar perfis de clientes

Conclusão

O Random Forest demonstrou excelente desempenho com 84.50% de acurácia na classificação de risco de crédito. As features mais relevantes foram Checking account, Credit amount e Duration. O K-Means identificou 3 perfis distintos de clientes, revelando padrões úteis para estratégias de concessão de crédito.

A combinação dos dois métodos oferece uma solução completa: predição automatizada (Random Forest) para decisões de aprovação + segmentação estratégica (K-Means) para análise de perfis de clientes.

Repositório GitHub

<https://github.com/MatheusCampioto/trabalho-ia-credito>